Diyabetik Retinopati Tespitine Yönelik Önceki Çalışmaların Karşılaştırmalı Literatür Özeti

1. Giriş

Diyabetik retinopati (DR), diyabetin neden olduğu ve retinanın kan damarlarına zarar vererek görme kaybına, ileri evrelerde ise körlüğe yol açabilen ciddi bir göz komplikasyonudur. Bu hastalık dünya çapında milyonlarca insanı etkilemektedir. Uluslararası Diyabet Federasyonu'nun verilerine göre dünya genelinde 537 milyondan fazla insanı etkilemektedir[1].90 milyon diyabet hastası diyabetik retinopatiye sahiptir[2]. Diyabetik retinopati (DR), retinadaki kan damarlarının şişmesine ve göz içine sıvı sızmasına neden olarak retinayı etkiler. Bu komplikasyon görmeyi olumsuz etkiler ve körlüğe yol açabilir (körlük vakalarının yaklaşık %2,6'sı retinopati hastalığından kaynaklanmaktadır [3]). DR'nin klinik sınıflandırması beş evreye dayanmaktadır: Evre 0 (DR yok), Evre 1 (Hafif – Mild), Evre 2 (Orta – Moderate), Evre 3 (Şiddetli – Severe) ve Evre 4 (Proliferatif – Proliferative DR).

Bu hastalığın erken evrede tespit edilmesi, hastaların retinasının normal durumuna geri dönmesine yardımcı olur ve körlüğü önler [4]. Ancak diyabetik retinopatinin geleneksel manuel yöntemlerle tespiti, büyük miktardaki verinin işlenmesi nedeniyle oldukça zaman alıcıdır. Ayrıca bu geleneksel yöntemler çok sayıda yanlış sınıflandırmaya neden olmaktadır [5]. Manuel yöntemin aksine, bilgisayar destekli karar destek sistemleri diyabetik retinopatiyi daha hassas bir şekilde tespit etmektedir. Bu nedenle diyabetik retinopatinin tespiti için geliştirilen karar destek sistemleri erken teşhis açısından büyük önem taşımaktadır.

Diyabetik retinopatinin en erken belirtisi, kan damarlarının duvarlarının zayıflaması sonucu oluşan kırmızı, dairesel noktalar şeklinde görülen mikroanevrizma (MA) lezyonlarıdır. Bu noktaların boyutu 125 µm'den küçüktür ve keskin sınırlara sahiptir. Arrigo ve arkadaşlarına göre [6], MA'nın sakküler, fokal şişkinlik, fusiform, karışık, pedinküllü ve düzensiz olmak üzere 6 ana tipi vardır ve bunlar Şekil 1'de gösterilmiştir[7].

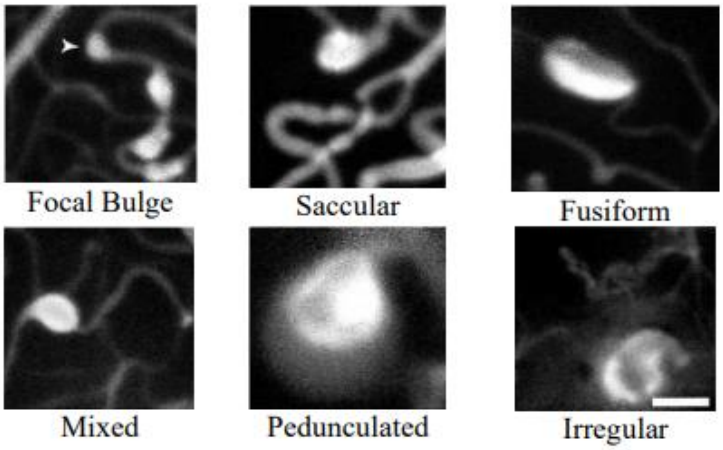

Bu literatür özeti; diyabetik retinopati tespitine odaklanan beş özgün çalışmayı kapsamlı biçimde incelemekte, yöntemlerini karşılaştırmakta ve mevcut araştırma boşluklarını ortaya koymaktadır. İncelenen çalışmalar sırasıyla: Hamza ve ark. (2024) [8], Minarno ve ark. (2022) [9], Manoj ve Bhosale (2024) [10], Şanver ve Saygılı (2024) [11] ile Toygar ve Jabbarbabouei (2025) [12]'dir.

2. İncelenen Çalışmalar ve Özet Bilgiler

2.1. Hamza ve ark. (2024) – CNN ve Makine Öğrenmesi Algoritmalarının Karşılaştırması

Bu çalışma, retinal görüntüler aracılığıyla diyabetin erken tespitini optimize etmek amacıyla beş farklı algoritmayı karşılaştırmıştır: Evrişimli Sinir Ağları (CNN), Rastgele Orman (Random Forest), Destek Vektör Makinesi (SVM), Gradyan Artırma (Gradient Boosting) ve K-En Yakın Komşu (KNN). Çalışmada APTOS 2019, MESSIDOR, IDRiD ve DIARETDB1 veri setlerinden derlenen, veri artırma teknikleri ile 15.000 görüntüye genişletilmiş bir veri seti kullanılmıştır [8]. Görüntü ön işleme aşamasında CLAHE (Kontrast Sınırlı Uyarlanabilir Histogram Eşitleme), keskinleştirme filtreleri ve Gauss Bulanıklığı uygulanmış; veri artırma için döndürme, yatay/dikey çevirme, yakınlaştırma ve parlaklık ayarları kullanılmıştır. Modeller eğitim (%80) ve test (%20) olarak bölünmüş; doğruluk, kesinlik, duyarlılık, F1-skoru ve ROC-AUC metrikleri ile değerlendirilmiştir.

Çizelge 1. Hamza ve ark. (2024) – Algoritma Başarım Karşılaştırması

Algoritma	Doğruluk (%)	Kesinlik (%)	Duyarlılık (%)	F1-Skoru (%)	ROC-AUC (%)
CNN	97.2	96.8	97.0	96.9	99.0
Gradient Boosting	87.1	86.2	87.0	86.6	93.1
Random Forest	85.0	84.5	85.0	84.7	91.5
SVM	82.5	81.9	82.3	82.1	89.2
KNN	78.2	77.6	78.0	77.8	85.6

Kaynak: Hamza ve ark. (2024) [1]

Tablo 1'de görüldüğü üzere CNN'nin %97,2 doğruluk ve %99,0 ROC-AUC ile diğer tüm modellerin önüne geçtiğini ortaya koymuştur. Bunu sırasıyla Gradyan Artırma (%87,1), Rastgele Orman (%85,0), SVM (%82,5) ve KNN (%78,2) izlemiştir. CNN'nin üstünlüğü, evrişimsel katmanlar sayesinde retinal yapılardan hiyerarşik özellik çıkarabilmesiyle açıklanmaktadır.Ancak çalışma; doğrulama kaybı (validation loss) grafiklerinde overfitting (aşırı uyum) belirtileri tespit etmiş olup bu durum, modelin yeni verilere genellenebilirliğini sınırlayabilmektedir.

2.2. Minarno ve ark. (2022) – EfficientNet-B7 ile Diyabetik Retinopati Sınıflandırması

Bu çalışma, APTOS 2019 veri seti üzerinde EfficientNet-B7 mimarisini kullanarak DR'nin beş sınıfa (Yok, Hafif, Orta, Şiddetli, Proliferatif) ayrımını gerçekleştirmiştir [9]. Bu çalışmanın ana odak noktası, Harikrishnan, Ben Graham ve Usuyama gibi farklı ön işleme (preprocessing) tekniklerinin modele etkisini ölçmektir. Usuyama ön işleme tekniği ile EfficientNet-B7 modelinin test verisinde %84 doğruluğa ulaştığı gözlemlenmiştir.

Usuyama ön işleme tekniği, eğitim verisinde %89,1 ve test verisinde %84,4 doğruluk ile en iyi sonucu vermiştir. Çalışma, ön işleme seçiminin model başarımını doğrudan etkilediğini ve uygun veri artırmanın aşırı uyum sorununu azaltabileceğini kanıtlamıştır. Ancak beş sınıf arasındaki dengesiz veri dağılımı (özellikle Şiddetli DR'nin çok az örneğe sahip olması) sınırlı genellenebilirlik sorununa yol açmaktadır.

2.3. Manoj S H ve Bhosale (2024) – Transfer Öğrenimi ve U-Net ile Segmentasyon Tabanlı Tespit

Bu çalışma, DR tespitini yalnızca sınıflandırma düzeyinde ele almak yerine; lezyon segmentasyonu, hastalık derecelendirmesi ve tedavi önerisini bir araya getiren kapsamlı bir sistem önermektedir [10]. Segmentasyon için U-Net mimarisi kullanılmış; kan damarları, sert eksüdalar, yumuşak eksüdalar, hemorajiler, mikroanevrizmaların ve optik diskin piksel düzeyinde belirlenmesi hedeflenmiştir. APTOS 2019, IDRiD ve MESSIDOR veri setleriyle eğitim gerçekleştirilmiş; Kaggle Diyabetik Retinopati Tespit Yarışması 2015 ile ön eğitim (pretraining) yapılmıştır.

Çizelge 3. Manoj ve Bhosale (2024) – U-Net Segmentasyon Başarım Metrikleri

Lezyon Türü	Jaccard	F1-Skoru	Duyarlılık	Kesinlik	Doğruluk
Kan Damarları	0.6634	0.7974	0.7771	0.8240	0.9922
Sert Eksüdalar	0.6663	0.7953	0.7841	0.8069	0.9986
Yumuşak Eksüdalar	0.6679	0.7874	0.7698	0.8053	0.9981
Hemorajiler	0.6551	0.7874	0.7612	0.8145	0.9958
Mikroanevrizmaların	0.6761	0.8061	0.7894	0.8233	0.9967
Optik Disk	0.6638	0.7956	0.7801	0.8117	0.9989

Çizelge 3'te görüldüğü üzere tüm lezyon sınıflarında Jaccard skoru 0.65–0.68, F1-skoru 0.79–0.81, doğruluk değeri ise 0.99'un üzerinde gerçekleşmiştir. Model saniyede 361 kare (FPS) işleyebilmekte ve böylece gerçek zamanlı klinik uygulamalara uygunluk sağlamaktadır. Ayrıca ChatGPT tabanlı bir büyük dil modeli (LLM) entegrasyon sistemi aracılığıyla segmentasyon çıktılarına dayanan test ve tedavi önerileri oluşturulmuştur. Bu yapı, DR yönetiminde karar destek sistemlerine yeni bir boyut kazandırmaktadır.

2.4. Şanver ve Saygılı (2024) -YOLOv8 Tabanlı Gerçek Zamanlı Diyabetik Retinopati Sınıflandırması

Şanver ve Saygılı [11], nesne tespiti alanında yaygın olarak kullanılan YOLOv8 (You Only Look Once) mimarisini DR sınıflandırmasına uyarlayarak özgün bir yaklaşım sunmaktadır. Kaggle Diyabetik Retinopati Tespiti veri setinden elde edilen, 224×224 piksel çözünürlüğünde ve beş farklı sınıfa (No_DR: 1.212, Moderate: 690, Mild: 270, Proliferate_DR: 219, Severe: 137) ait toplam 3.600 fundus görüntüsü kullanılmıştır. Çalışmanın kritik özelliği; herhangi bir ön işleme, veri artırma veya sınıf dengeleme işlemi uygulanmadan ham verilerin kullanılmasıdır.

Model; 10 katman, 1.444.693 parametre, Adam optimizer (dropout=0.2) ile yapılandırılmış ve 50 epoch eğitilmiştir. Deneyler iki CPU (CPU1, CPU2) ve iki GPU (GPU1, GPU2) olmak üzere dört farklı donanım konfigürasyonunda gerçekleştirilmiştir. GPU ile eğitim

yalnızca 5 dakika sürerken CPU ile bu süre 35 dakikaya çıkmıştır. Bu dramatik fark, YOLOv8'in GPU hızlandırmasından azami ölçüde yararlandığını ve klinik ortamlarda hızlı prototiplemeye olanak tanıdığını göstermektedir.

Çizelge 4. Şanver ve Saygılı (2024) – YOLOv8 Donanım Konfigürasyonlarına Göre Başarım

Konfigürasyon	No_DR F1	Moderate F1	Mild F1	Prolif. F1	Severe F1
CPU1 (%83)	0.97	0.78	0.52	0.63	0.32
CPU2 (%83)	0.97	0.78	0.52	0.65	0.30
GPU1 (%84.91) ★	0.97	0.81	0.56	0.63	0.41
GPU2 (%84.36)	0.97	0.79	0.62	0.60	0.39

En yüksek doğruluk değeri | Kaynak: Şanver ve Saygılı (2024) [11]

Çizelge 4, sınıf bazlı analizde No_DR sınıfının tüm konfigürasyonlarda %97 F1-skoru ile en başarılı sonucu verdiğini, buna karşın Severe sınıfının en düşük başarımda kaldığını (F1: 0.30–0.41) açıkça ortaya koymaktadır. Mild sınıfının Moderate ile sık sık karıştırılması, bu iki evrenin retinal görüntülerde benzer görünüm sergilemesinden kaynaklanmaktadır. Karışıklık matrisi analizi, özellikle No_DR ve Moderate sınıflarında en az hatanın meydana geldiğini, Severe sınıfında ise en yüksek hata oranının görüldüğünü teyit etmektedir.

2.5. Toygar ve Jabbarbabouei (2025) – Gelenekselden Derin Öğrenmeye Geçiş ve VGG16+PCA Hibrit Modeli

Toygar ve Jabbarbabouei [12], DR sınıflandırması için el-yapımı (hand-crafted) özellik çıkarma yöntemleri ile derin öğrenme modellerini sistematik biçimde karşılaştırmakta ve VGG16 derin öğrenme mimarisi ile Ana Bileşen Analizi'ni (PCA) birleştiren hibrit bir model önermektedir. Çalışmada iki ayrı veri seti kullanılmıştır: APTOS 2019 (3.662 görüntü, 5 sınıf) ve Messidor-2 (1.748 görüntü, 5 sınıf). El-yapımı yöntemler olarak PCA ve Yerel İkili Örüntüler (LBP) uygulanmıştır; derin öğrenme modelleri ise VGG16, InceptionV3, MobileNetV3, DenseNet201 ve özel CNN'dir.

Ön işleme aşamasında tüm görüntüler 224×224 piksel olarak yeniden boyutlandırılmış, piksel değerleri 0-1 arasında normalleştirilmiş ve veri dengesizliğini gidermek amacıyla döndürme, yakınlaştırma ve kaydırma işlemleri uygulanmıştır. Veri seti %80 eğitim / %10 doğrulama / %10 test olarak bölünmüştür. Tüm derin öğrenme modelleri Adam optimizer (öğrenme oranı 0.01) ile eğitilmiş; aşırı uyumu önlemek amacıyla erken durdurma (Early Stopping) algoritması kullanılmıştır.

Önerilen hibrit modelde VGG16, özellik çıkarıcı olarak kullanılmış (uçtan uca sınıflandırma yapılmadan) ve ardından PCA ile boyut indirgeme gerçekleştirilmiştir. DenseNet201+PCA kombinasyonu yerine VGG16+PCA'nın tercih edilmesinin temel nedeni; DenseNet201'in ürettiği yüksek boyutlu özellik haritalarına PCA uygulandığında önemli ayrıştırıcı bilgilerin kaybolmasıdır. VGG16'nın daha ılımlı ve yapılandırılmış özellik temsili, PCA'nın boyut indirgeme sürecinde kritik bilgileri korumasına olanak tanımaktadır. Son sınıflandırma adımında En Yakın Komşu (Nearest-Neighbor – NN) sınıflandırıcısı kullanılmıştır.

Çizelge 5. Toygar ve Jabbarbabouei (2025) – APTOS 2019 Veri Seti Sonuçları

Model	Doğruluk (%)	Kesinlik (%)	Duyarlılık (%)	AUC (%)

VGG16+PCA (Önerilen) ★	91.10	91.20	90.60	99.14
DenseNet201	89.17	95.81	81.80	98.73
InceptionV3	86.83	94.67	79.35	98.59
VGG16	83.59	92.74	77.00	97.03
CNN	83.48	92.43	73.66	96.78
MobileNetV3	52.12	96.66	22.65	82.83
PCA (El-yapımı)	68.97	68.60	68.97	77.77
LBP (El-yapımı)	66.55	65.37	66.55	75.26

★ En iyi sonuç | Kaynak: Toygar ve Jabbarbabouei (2025) [5]

Çizelge 5, hibrit modelin (VGG16+PCA) APTOS 2019 veri setinde %91.10 doğruluk ve %99.14 AUC ile diğer tüm modellerin önüne geçtiğini açıkça ortaya koymaktadır. MobileNetV3'ün yalnızca %52.12 doğruluk ve %22.65 duyarlılık elde etmesi, modelin retinal özellikleri yeterince yakalayamadığına işaret etmektedir. El-yapımı PCA ve LBP yöntemlerinin derin öğrenme modellerinin gerisinde kalması, otomatik özellik öğreniminin medikal görüntü analizindeki üstünlüğünü teyit etmektedir.

Çizelge 6. Toygar ve Jabbarbabouei (2025) – Messidor-2 Veri Seti Sonuçları

Model	Doğruluk (%)	Kesinlik (%)	Duyarlılık (%)	AUC (%)
CNN ★	86.87	92.89	81.66	98.38
VGG16+PCA (Önerilen)	85.00	88.61	86.02	97.23
MobileNetV3	84.79	91.84	82.08	98.23
DenseNet201	84.79	88.27	83.12	98.20
VGG16	83.33	87.32	77.49	95.92
InceptionV3	82.91	91.95	78.54	97.69
PCA (El-yapımı)	63.18	61.72	63.18	75.38
LBP (El-yapımı)	60.25	59.13	60.25	73.47

★ En yüksek doğruluk | Kaynak: Toygar ve Jabbarbabouei (2025) [5]

Messidor-2 sonuçlarında CNN %86.87 ile en yüksek doğruluğu elde etmiştir. Ancak önerilen VGG16+PCA modeli, en yüksek duyarlılığı (%86.02) sergileyerek pozitif vakaları tespit etmede en güvenilir modelin hibrit yaklaşım olduğunu göstermektedir. Bu bulgu, klinik açıdan kritik öneme sahiptir; zira bir DR tarama sisteminde yüksek duyarlılık, hastalıklı vakaların gözden kaçırılmaması için yüksek doğruluktan daha öncelikli bir hedeftir.

3. Çalışmaların Karşılaştırmalı Analizi

Bu çalışmalar, DR tespiti problemine farklı metodolojik bakış açılarıyla yaklaşmaktadır.

Bu bölümde çalışmalar; kullandıkları mimari, veri seti büyüklüğü, ön işleme yaklaşımı, değerlendirme metrikleri ve elde ettikleri sonuçlar açısından karşılaştırılmaktadır.

Çizelge 7. İncelenen Çalışmaların Genel Metodolojik Karşılaştırması

Çalışma	Mimari	Veri Seti	Ön İşleme	En İyi Doğruluk	Sınıf Sayısı
Hamza (2024)	CNN, RF, SVM, GB, KNN	15.000 (çok kaynak)	CLAHE, Gauss, Aug.	%97.2 (CNN)	5
Minarno (2022)	EfficientNet-B7	3.662 (APTOS)	3 teknik karş.	%84.36 (test)	5
Manoj (2024)	U-Net + ChatGPT	~37.000 (çok kaynak)	PyTorch özel	Kappa: 0.9255	5 + segm.
Şanver (2024)	YOLOv8	3.600 (Kaggle)	Ön işleme yok	%84.91 (GPU1)	5
Toygar (2025)	VGG16+PCA (Hibrit)	APTOS+Messidor-2	Norm.+Aug.+Split	%91.10 (APTOS)	5

Çizelge 7. Beş çalışmanın mimari, veri ve başarım açısından özet karşılaştırması

Hamza ve ark.[8] geniş algoritma karşılaştırması yaparak CNN'nin klasik makine öğrenmesi yöntemleri karşısındaki üstünlüğünü nicel olarak ortaya koymuştur. Bu çalışma, birden fazla veri setini birleştirme ve kapsamlı veri artırma stratejileri açısından güçlü bir metodoloji sunmaktadır. Minarno ve ark. ise tek bir derin öğrenme modeline (EfficientNet-B7) odaklanarak ön işleme tekniklerinin ve hiperparametre optimizasyonunun model başarımı üzerindeki etkisini sistematik biçimde incelemiştir. Bu yaklaşım, daha kontrollü bir deneysel tasarım sağlamakla birlikte yalnızca bir veri setiyle (APTOS 2019) sınırlı kalmıştır. Manoj ve Bhosale ise segmentasyon, sınıflandırma ve klinik karar destek sistemini bir arada ele alarak en kapsamlı sistem yaklaşımını ortaya koymuştur.

Veri seti açısından değerlendirildiğinde; Hamza ve ark. 15.000 artırılmış görüntü kullanırken Minarno ve ark. yalnızca 3.662 orijinal görüntüyle çalışmıştır. Manoj ve Bhosale ise birden fazla veri setini ön eğitim ve değerlendirme amacıyla ayrı ayrı kullanmıştır. Değerlendirme metrikleri açısından Hamza ve ark. ROC-AUC dahil en kapsamlı metrik setini sunmuştur. Ön işleme teknikleri karşılaştırıldığında; Hamza ve ark. ile Minarno ve ark.'nın her ikisi de Gauss bulanıklığı ve normalizasyon kullandığı, ancak Minarno ve ark.'nın dairesel kırpma ile ek kontrast iyileştirme adımlarını sistematik olarak test ettiği görülmektedir. Manoj ve Bhosale ise PyTorch tabanlı özel bir ön işleme sınıfı geliştirerek U-Net girişi için normalizasyon ve kanal transpozizyonu uygulamıştır.

4. Tespit Edilen Araştırma Boşlukları

4.1. Açıklanabilirlik ve Şeffaflık Eksikliği

İncelenen çalışmaların hiçbirinde model kararlarını klinisyenlere anlaşılır biçimde açıklamak amacıyla Açıklanabilir Yapay Zeka (XAI) yöntemleri yeterince entegre edilmemiştir. CNN, EfficientNet-B7 ve YOLOv8 gibi modellerin yüksek doğruluğu, klinik ortamlarda yorumlanabilirlik (interpretability) açısından ciddi sorunlar doğurmaktadır. Toygar ve Jabbarbabouei [12] bu sınırlılığı gelecek çalışmalar için açıkça kaydetmiş olmakla birlikte, hiçbir çalışmada GRAD-CAM, LIME veya SHAP gibi araçlar sistematik biçimde uygulanmamıştır. Bu araçların entegrasyonu hem tıbbi güvenilirliği artıracak hem de klinisyenlerin sisteme olan güvenini pekiştirecektir.

4.2. Dengesiz Veri Dağılımı ve Model Adaleti

Tüm çalışmalarda, özellikle Şiddetli DR (Severe) ve Proliferatif DR sınıflarında belirgin veri dengesizliği gözlemlenmiştir. Şanver ve Saygılı [11], Severe sınıfının yalnızca 137 eğitim örneğine sahip olduğunu raporlamış ve bu durumun F1-skoru üzerindeki olumsuz etkisini sayısal olarak ortaya koymuştur. Toygar ve Jabbarbabouei [12], Messidor-2 veri setinde Evre 4'ün yalnızca 35 örneğe sahip olduğunu belirtmiştir. Hamza ve ark. [8] veri artırmayla bu sorunu kısmen gidermeye çalışmış olsa da yapay örneklerin gerçek klinik çeşitliliği temsil edip etmediği tartışmalı kalmaktadır. Model adaleti sorunları, yani belirli hasta alt gruplarında veya hastalık evrelerinde performansın düşmesi, incelenen çalışmaların hiçbirinde sistematik biçimde ele alınmamıştır.

4.3. Sınırlı Genellenebilirlik ve Demografik Çeşitlilik

Çalışmaların büyük çoğunluğu sınırlı veri setleri üzerinde eğitilmiştir; bu durum, modellerin farklı demografik gruplar, kameralar ve klinik ortamlara genellenebilirliğini olumsuz etkilemektedir. Hamza ve ark. birden fazla veri seti kullanmış olsa da bu veri setleri coğrafi ve demografik çeşitlilik açısından hâlâ kısıtlıdır. Federe öğrenme (federated learning) yaklaşımları, hasta gizliliğini korurken çok merkezli eğitime imkân tanıyarak bu sorunu çözme potansiyeline sahiptir; ne var ki incelenen çalışmalarda bu yöntem uygulanmamıştır.

4.4. Çok Kipli Veri Entegrasyonunun Yokluğu

Manoj ve Bhosale, LLM entegrasyonu ile bu yönde ilk adımı atmış olsa da incelenen çalışmaların hiçbiri retinal görüntüleri klinik metabolik veriler, genetik bilgiler veya hasta geçmişiyle sistematik biçimde birleştirmemiştir. Çok kipli (multimodal) yaklaşımların DR'nin yalnızca bulgularını değil, hastalığın altında yatan patofizyolojisini de aydınlatabilmesi ve tahmin doğruluğunu artırması beklenmektedir.

4.5. Gerçek Zamanlı Klinik Entegrasyon ve Ölçeklenebilirlik

Şanver ve Saygılı [11], YOLOv8'in gerçek zamanlı nesne tespitindeki hız avantajına dikkat çekmiş; GPU kullanıldığında 50 epoch eğitimin 5 dakikada tamamlanabildiğini göstermiştir. Manoj ve Bhosale [10] bir web uygulaması önermiş ve modelinin saniyede 361 kare işleyebildiğini raporlamıştır. Ancak hiçbir çalışmada model, gerçek bir klinik bilgi sistemiyle entegre edilmemiş ve ölçeklenebilirlik analizleri yapılmamıştır. Özellikle düşük kaynaklı ortamlarda hesaplama verimliliği, mobil veya uç cihazlara dağıtım (edge

deployment) ve elektronik sağlık kayıtları ile interoperabilite, gelecekteki çalışmalarda öncelikli olarak ele alınması gereken konular arasındadır.

4.6. Dengesiz Veri ve Model Adaleti Sorunları

Tüm çalışmalarda, özellikle Şiddetli DR sınıfında belirgin veri dengesizliği sorunu gözlemlenmiştir. Hamza ve ark. veri artırma yoluyla bu sorunu kısmen gidermeye çalışmış, ancak yapay örneklerin gerçek klinik çeşitlilik ile tam anlamıyla örtüşüp örtüşmediği tartışmalı kalmaktadır. Model adaleti sorunları, yani belirli hasta gruplarında performansın düşmesi, sistematik olarak incelenmemiş ve raporlanmamıştır.

5. Sonuç

Bu literatür özeti; diyabetik retinopati tespitine yönelik beş özgün çalışmayı kapsamlı biçimde incelemiş ve karşılaştırmalı bir analiz sunmuştur. Elde edilen bulgular, derin öğrenme tabanlı yaklaşımların geleneksel el-yapımı özellik çıkarma yöntemlerine kıyasla medikal görüntü analizinde belirgin biçimde üstün olduğunu doğrulamaktadır.

Hamza ve ark. [8], CNN'nin makine öğrenmesi yöntemleri karşısında %97.2 doğrulukla rakipsiz üstünlüğünü ortaya koymuştur. Minarno ve ark. [9], ön işleme tekniklerinin model başarımı üzerindeki kritik etkisini sistematik biçimde kanıtlamıştır. Manoj ve Bhosale [3], segmentasyonu, sınıflandırmayı ve LLM tabanlı karar desteğini birleştirerek en bütüncül sistem yaklaşımını ortaya koymuştur. Şanver ve Saygılı [11], ön işleme yapmaksızın YOLOv8 ile makul doğruluk değerlerine ulaşılabileceğini kanıtlamış; bu bulgu kaynak kısıtlı ve hız odaklı uygulamalar açısından değerlidir. Toygar ve Jabbarbabouei [12] ise hibrit VGG16+PCA modeliyle derin öğrenme ve geleneksel yöntemlerin güçlü yanlarını birleştirerek APTOS 2019'da %91.10 ve Messidor-2'de %85.00 doğruluk elde etmiştir.

Bununla birlikte beş çalışmada da ortak araştırma boşlukları tespit edilmiştir: açıklanabilirlik yöntemlerinin yokluğu, dengesiz veri dağılımı ve model adaleti sorunları, sınırlı demografik çeşitlilik, çok kipli veri entegrasyonunun yetersizliği ve gerçek klinik ortamlara entegrasyon eksikliği. Bu boşlukları gidermek üzere; GRAD-CAM ve SHAP gibi XAI araçlarının entegre edilmesi, federe öğrenme yaklaşımları, retinal görüntülerin klinik verilerle birleştirilmesi ve uç cihaz dağıtımına yönelik model optimizasyonu gelecek araştırmalar için öncelikli hedefler olarak öne çıkmaktadır.

Referanslar

[1] diabetesatlas, "IDF Diabetes Atlas 2022 Reports," [Online]. Available: https://diabetesatlas.org/. [Accessed 20 1 2023]

[2] B. Mounirou, N. Adam, A. Yakoura, M. Aminou, Y. Liu and L. Tan, "Diabetic Retinopathy: An Overview of Treatments," Indian J Endocr Metab, vol. 26, no. 2, pp. 111-118, 2022.

[3] R. Bourne, G. A. Stevens, R. A. White, J. L. Smith, S. R. Flaxman, H. Price and J. B. Jonas, "Causes of vision loss worldwide, 1990–2010: a systematic analysis," The lancet global health , vol. 1, no. 6, pp. 339-349, 2013.

[3] Minarno, A. E., Mandiri, M. H. C., Azhar, Y., Bimantoro, F., Nugroho, H. A., & Ibrahim, Z. (2022). Classification of Diabetic Retinopathy Disease Using Convolutional Neural Network. International Journal on Informatics Visualization, 6(1), 12–18.

[4] M. D. Saleh and C. Eswaran, "An automated decision-support system for non-proliferative diabetic retinopathy disease based on MAs and HAs detection," Computer methods and programs in biomedicine, vol. 108, no. 1, pp. 186-196, 2012

[5] W. L. Alyoubi, W. M. Shalash and M. F. Abulkhair, "Diabetic retinopathy detection through deep learning techniques: A review," Informatics in Medicine Unlocked, vol. 20, 2020.

[6] A. Arrigo, M. Teussink, E. Aragona, F. Bandello and M. B. Parodi, "MultiColor imaging to detect different subtypes of retinal microaneurysms in diabetic retinopathy," Eye , vol. 1, pp. 277-281, 2021.

[7] M. Dubow, A. Pinhas, N. Shah, R. Cooper, A. Gan, R. Gentile and V. Hendrix, "Classification of human retinal microaneurysms using adaptive optics scanning light ophthalmoscope fluorescein angiography," Investigative ophthalmology & visual science, vol. 55, no. 3, pp. 1299-1309, 2014.

[7] W. L. Alyoubi, W. M. Shalash and M. F. Abulkhair, "Diabetic retinopathy detection through deep learning techniques: A review," Informatics in Medicine Unlocked, vol. 20, 2020.

[8] Hamza, M., Obaidullah, & Shahwaiz, A. (2024). Optimizing Early Detection of Diabetes through Retinal Imaging: A Comparative Analysis of Deep Learning and Machine Learning Algorithms. Journal of Computational Informatics and Business, 1(1).

[9] Minarno, A. E., Mandiri, M. H. C., Azhar, Y., Bimantoro, F., Nugroho, H. A., & Ibrahim, Z. (2022). Classification of Diabetic Retinopathy Disease Using Convolutional Neural Network. International Journal on Informatics Visualization, 6(1), 12–18.

[10] Manoj, S. H., & Bhosale, A. A. (2024). Detection and Classification of Diabetic Retinopathy using Deep Learning Algorithms for Segmentation to Facilitate Referral Recommendation for Test and Treatment Prediction. The National Institute of Engineering, Mysore.

[11] Şanver, Ö., & Saygılı, A. (2024). Diagnosis and Classification of Diabetic Retinopathy with YOLOv8-Based Deep Learning Model. Kahramanmaraş Sütçü İmam Üniversitesi Mühendislik Bilimleri Dergisi, 27(4), 1297–1305.

[12] Toygar, Ö., & Jabbarbabouei, Z. (2025). Diabetic Retinopathy Detection Models: Transition from Conventional to Deep Learning Approaches and a Hybrid Model. Pamukkale University Journal of Engineering Sciences.